




ChemAI: Predict the Cure

Хакатон по машинному обучению в фармацевтике — предсказание эффективности химических соединений против вируса гриппа

НИЯУ МИФИ · ГРУППА M25-555

МОСКВА, 2026

Команда

- **Анастасия Волконская** — тимлид, ML-инженер, аналитик
- **Алина Давыденко** — ML-инженер, аналитик
- **Артур Сидоров** — ML-инженер, аналитик
- **Максим Власюк** — ML-инженер, аналитик
- **Мария Макарова** — ML-инженер, аналитик

Цель задачи и метрика

По условию хакатона (ТЗ, раздел «Проблема»), разработка новых лекарственных препаратов — сложный и длительный процесс, включающий синтез соединений и их биологическое тестирование. Современные методы машинного обучения позволяют ускорить этот процесс, предсказывая эффективность химических соединений до проведения лабораторных экспериментов. В этом соревновании мы выступаем в роли ML и Data-инженеров в команде фармацевтической разработки: химики предоставили данные о свойствах молекул и их биологической активности против вируса гриппа.

Что предсказываем

Три скалярных таргета — **IC50**, **CC50**, **SI** — для малых молекул по набору ≈ 210 числовых признаков (дескрипторы RDKit: Топо/logP/VSA, фрагменты fr_* и др.)

Формат соревнования

Одна таблица отправки с колонками **index**, **IC50**, **CC50**, **SI** для тестовой выборки

Метрика (скоринг)

Среднее арифметическое RMSE по трём столбцам:

$(RMSE_{IC50} + RMSE_{CC50} + RMSE_{SI})/3$. В коде проекта — логика «среднее по трём RMSE» после согласования длины и отсутствия NaN

Данные и предметная интерпретация

Состав набора данных

Train

751 строка: индекс + 3
таргета + 210 признаков

Test

250 строк: индекс + те же
210 признаков

Ключевое доменное тождество

На обучающей выборке **SI численно совпадает с CC50 / IC50** (до машинной погрешности). Это фундаментальное соотношение селективного индекса — не артефакт данных, а предметное тождество.

Знание этой связи открывает возможности для:

- Экспериментов по согласованности столбцов
- Построения гибридных предсказаний SI через отношение CC50/IC50
- Контроля качества предсказаний на валидации

Основные факты EDA

Разведочный анализ данных выявил четыре ключевых особенности, определивших архитектуру пайплайна.



Тяжёлые правые хвосты

IC50 и CC50 имеют сильную асимметрию распределения. Применено **log1p**-преобразование при обучении и **expm1** на выходе модели для корректного восстановления масштаба.



Шум и пропуски

Константные и почти константные признаки, редкие пропуски. Реализован **Preprocessor** с отсевом слабоинформативных столбцов и импутацией.



Умеренные корреляции

Корреляции отдельных дескрипторов с таргетами лишь умеренные — ни один признак не объясняет активность сам по себе. Требуются **многопризнаковые** бустинг/леса и регуляризованные линейные модели.



~16% дубликатов

Каждая шестая строка — дубликат по признаковому вектору. Наивный CV смешивает «соседей» и завышает качество. Решение — **ClusterKFold**, группирующий дубли в один фолд.

Covariate Shift: Train → Test

Что обнаружено

Зафиксирован **сдвиг средних и состава** между train и test по ряду признаков — в том числе отдельные фрагментные дескрипторы **fr_***, размерность и форма колец и другие структурные характеристики молекул.

⚠ Риск переоценки качества: если судить только по train-валидации, можно получить завышенные ожидания на платформе.

Ответ пайплайна

- Использование **устойчивых к локальному смещению** семейств моделей (деревья, бустинг)
- **Нет утечки** теста в препроцессинг — все преобразования строятся только на train
- Переобучение препроцессора **только внутри train-фолда** в рамках ClusterKFold
- Честная оценка обобщающей способности без «подглядывания» в тест

Базовое решение: [train.py](#)

Воспроизводимый baseline-пайплайн, закреплённый в репозитории, обеспечивает честную кросс-валидацию и готов к использованию в CI/CD.

Преобработка по
фолдам
Fit/transform на каждом
фолде без утечки.

Три целевых
пространства
IC50, CC50 и SI с весами CV.

ClusterKFold

Разбивать только по train-
индексам.

Сохранение
артефактов

preprocessor, pipeline_bundle
и metrics.json.

Запуск обучения: `python run_pipeline.py --train`. Три параллельных выходных пространства (IC50, CC50, SI) имеют **собственные веса ансамбля** по CV — обратные среднему RMSE по фолдам с нормировкой. Все артефакты сохраняются в `ml/models_saved/`.

Ансамбль базовых моделей



Градиентный бустинг

LGBM, XGBoost, HistGBR, GBR — основные кандидаты первого уровня. На практике именно они задают финальный вклад в ансамбль благодаря устойчивости на разреженных дескрипторах.



Лесные методы

Random Forest и **ExtraTrees** — стабильные базовые модели с хорошей регуляризацией «из коробки». Дополняют бустинг в ансамбле, снижая дисперсию предсказаний.



Линейные модели

Ridge, ElasticNet, Bayesian Ridge со **StandardScaler**. Нестабильные на данных с умеренными корреляциями — часто получают микровеса после CV, но полезны в стекинге.



CatBoost

Опциональный кандидат. Сборка качества первого уровня — **взвешенное среднее** предсказаний без meta-learn stacking в базовом train.py.

Инференс и платформа

Запуск предсказания

```
python run_pipeline.py --predict
```

Генерирует **docs/submissions/final_submission.csv** с колонками **index**, **IC50**, **CC50**, **SI** и **postprocess**-преобразованиями (**exprm1**).

Роль 1: CI/CD репозиторий

Поддерживаемый пайплайн **train → predict → final_submission.csv**.
Воспроизводимость в git обеспечена.

Роль 2: Лучший платформенный скор

Лучший задокументированный публичный результат достигается через подходы класса **submission2_a4** / **submission3_a4** — с OOF Ridge stacking поверх базовых кандидатов при cluster-CV.

- ❗ Сценарий генерации отправок подробно описан в итоговой записке проекта. В узкой поддерживаемой сборке воспроизводимость обеспечивает связка **train/predict**.

Серия авторских отправок и лидерборд

Вариант	Идея	Публичный балл
submission2_a4	Cluster CV + базовые кандидаты + OOF Ridge stacking	~349.31
submission3_a4	+ подбор смеси SI с отношением CC50/IC50 (OOF вес смеси ≈ 1.0)	~349.31
submission4_a4	GroupKFold по дубликатам + stacking + SI-blend	~373.04
submission5_a4	+ Optuna над LightGBM	~373.04

Ключевой урок

«Более честная» групповая валидация (submission4/5) **не перевелась** в лучший платформенный скор. Лучшие результаты серии даёт **вариант 2/3** с OOF stacking при cluster-CV.

Интерпретация разрыва

GroupKFold-варианты давали более «честный» офлайн-скор по одной трактовке группировки, но **ухудшали** результат на платформе — признак переоптимизации под офлайн или расхождения со скрытым сплитом платформы.

Выводы

- 1** Данные — типичная табличная QSPR
Малая выборка (751 train), ~210 признаков, асимметрия активностей, дубликаты и covariate shift. Обобщение важнее «одного топ-признака».
- 2** Ядро репозитория — воспроизводимый **baseline**
ClusterKFold, честный фолдовый preprocessor, семейство сильных регрессоров и пер-таргетные веса ансамбля из CV.
- 3** Лучший платформенный результат ~**349.31**
Достигнут через **OOF Ridge stacking** поверх базовых кандидатов при cluster-CV — без правок train.py в исходной постановке экспериментов.
- 4** Разрыв **OOF vs Leaderboard**
GroupKFold ухудшал платформу — признак переоптимизации под офлайн или расхождения со скрытым сплитом платформы.
- 5** Резерв на будущее
Совместная оптимизация под среднее RMSE по трём столбцам, учёт связи SI с IC50/CC50, полноценный тюнинг (Optuna) и аккуратный group-split после проверки трансфера.